# 12 Giugno 2024

### Esercizio 1

In questo esercizio considereremo la funzione

$$f(x) = rac{6}{a^3}(ax-x^2)I_{[0,a]}(x)$$

dove  $I_A$  denota la funzione indicatrice dell'insieme A e a>0 è un parametro della funzione. Indicheremo inoltre con X una variabile aleatoria avente f come funzione di densità di probabilità, per un valore ignoto di a.

- 1. Dimostrate che f è una funzione di densità di probabilità per ogni valore reale a>0.
- 2. Calcolate il valore atteso di X esprimendola in funzione di a (suggerimento: ragionando su alcune proprietà geometriche, potete giustificare il risultato senza fare conti).
- 3. Indichiamo con F la funzione di ripartizione di X. Ricavate la forma analitica di F(x), esprimendola in funzione di x e a.
- 4. Supponete, **solo in questo punto**, che  $a=\frac{1}{2}$ . Scrivete ed eseguite del codice che disegni il grafico della funzione F definita al punto precedente.
- 5. Il grafico che avete ottenuto al punto 4 potrebbe suggerire che X segue una distribuzione normale? Perché? Validate o refutate questa ipotesi.
- 6. Calcolate fa varianza di X esprimendola in funzione di a.

## Esercizio 2

In questo esercizio considereremo una popolazione X la cui distribuzione è la stessa dell'omonima variabile aleatoria introdotta nell'esercizio precedente, dove a rappresenterà un parametro incognito. Per  $n \in \mathbb{N}$  fissato,  $X_1,\ldots,X_n$  indicheranno delle variabili aleatorie che descrivono un campione estratto da X.

- 1. Dimostrate che la media campionaria è uno stimatore **distorto** per il parametro a.
- 2. Calcolate il bias e lo scarto quadratico medio di  $\overline{X}$  rispetto ad  $a_i$  esprimendoli solo in funzione di n e a.
- 3. La media campionaria gode della proprietà di consistenza in media quadratica se la utilizziamo per stimare *a*? Motivate la vostra risposta.
- 4. Dovendo scegliere se applicare il metodo plug-in o il metodo della massima verosimiglianza per ottenere uno stimatore non distorto per *a*, quale opzione risulta più agevole? Perché?
- 5. Applicate i metodo scelto al punto precedente e determinate uno stimatore T che sia non distorto per a.
- 6. Utilizzando il teorema centrale del limite, determinate la distribuzione approssimata dello stimatore T che avete ottenuto al punto 5.
- 7. Calcolate la probabilità dell'evento che si verifica quando l'errore (in valore assoluto) che si compie usando T per stimare a sia minore o uguale di 1, esprimendola in funzione di a, n e della funzione di ripartizione della distribuzione normale standard, giustificando i vostri passaggi e indicando eventuali approssimazioni che è necessario introdurre.

# Esercizio 3

Collegatevi al sito upload di.unimi.it, selezionate l'esame di Statistica e analisi dei dati per l'appello odierno e scaricate il file risultati.csv. Questo file contiene le seguenti informazioni raccolte da un ipotetico centro di formazione relativamente ai risultati che i propri studenti e le proprie studentesse hanno ottenuto nella tornata annuale di un test di idoneità organizzato a livello nazionale da un Ministero.

- matricola: numero di matricola;
- genere: genere (codificato come 'F' oppure 'M');

12 Giugno 2024

- · eta: età;
- punteggio: punteggio conseguito al test:
- tempo: tempo necessario per terminare il test, espresso in minuti

In questo file il carattere , separa le colonne.

- 1. Scrivete ed eseguite del codice che visualizzi su righe differenti il nome di ogni attributo unitamente al corrispondente numero di valori mancanti.
- 2. Di che tipo è l'attributo genere? Sulla base della risposta data, visualizzate la distribuzione di questo attributo fornendo sia una formulazione tabulare, sia un grafica, motivando le vostre scelte.
- 3. Considerate l'attributo punteggio, e ripetete l'analisi svolta al punto precedente, valutando se debba essere fatta nello stesso modo oppure se debbano essere utilizzati strumenti diversi.
- 4. Valutate l'ipotesi che vi sia una relazione tra gli attributi punteggio e tempo, specificando eventualmente il tipo e la forza della relazione determinata. Quali strumenti avete utilizzato per valutare questa ipotesi? Perché?
- 5. Gli esperti del centro di formazione sospettano che l'attributo punteggio dovrebbe sia ben descritto da una distribuzione analoga a quella studiata nell'Esercizio 1. Scegliete uno strumento che ha senso utilizzare per validare questa ipotesi e applicatelo, commentando i risultati ottenuti.

#### Esercizio 4

I valori dell'attributo punteggio nel dataset considerato al punto precedente sono espressi in una scala il cui valore massimo a non è stato reso noto, e il centro di formazione vuole stimare questo valore.

- 1. Sulla base della soluzione che avete proposto per l'Esercizio 2, calcolate una stima per a.
- 2. Utilizzare il risultato dell'Esercizio 2.7 per stimare la probabilità che la stima ottenuta al punto precedente comporti un errore (in valore assoluto) minore o uguale di 1.
- 3. Indichiamo con X la variabile aleatoria che descrive il punteggio ottenuto. Il test si considera sostenuto con successo se si ottiene un punteggio superiore a 21. Calcolate la frequenza di questo evento nel dataset considerato e confrontatela con la probabilità P(X>21), calcolata sostituendo al parametro a la corrispondente stima ottenuta nel punto 1 di questo esercizio, commentando i risultati ottenuti.
- 4. Ipotizzando che sussista indipendenza tra i punteggi ottenuti nel test da persone diverse che lo sostengono, supponiamo che tre studenti o studentesse del centro svolgano il test in una stessa tornata, e indichiamo con Y la variabile aleatoria che indica il numero di test superati. Dite quale distribuzione segue questa variabile aleatoria, e calcolate le seguenti probabilità, esprimendo anche l'evento corrispondente in termini di Y:
  - a. tre persone svolgono il test nella stessa tornata, e tutte e tre lo superano;
  - b. tre persone svolgono il test nella stessa tornata, ma solo una tra esse lo supera;
  - c. tre persone svolgono il test nella stessa tornata, e al più una tra esse lo supera.
- 5. Ipotizzando che sussista indipendenza tra punteggi ottenuti da una stessa persona in tempi diversi, indichiamo con Z la variabile aleatoria che indica il numero di bocciature al test prima di superarlo. Dite quale distribuzione segue Z, e calcolate la probabilità dei seguenti eventi, esprimendo anche l'evento corrispondente in termini di Z:
  - a. una persona supera il test al quarte tentativo;
  - b. una persona che non ha superato il test al secondo tentativo deve svolgerlo nuovamente almeno due volte prima di superarlo.

12 Giugno 2024 2